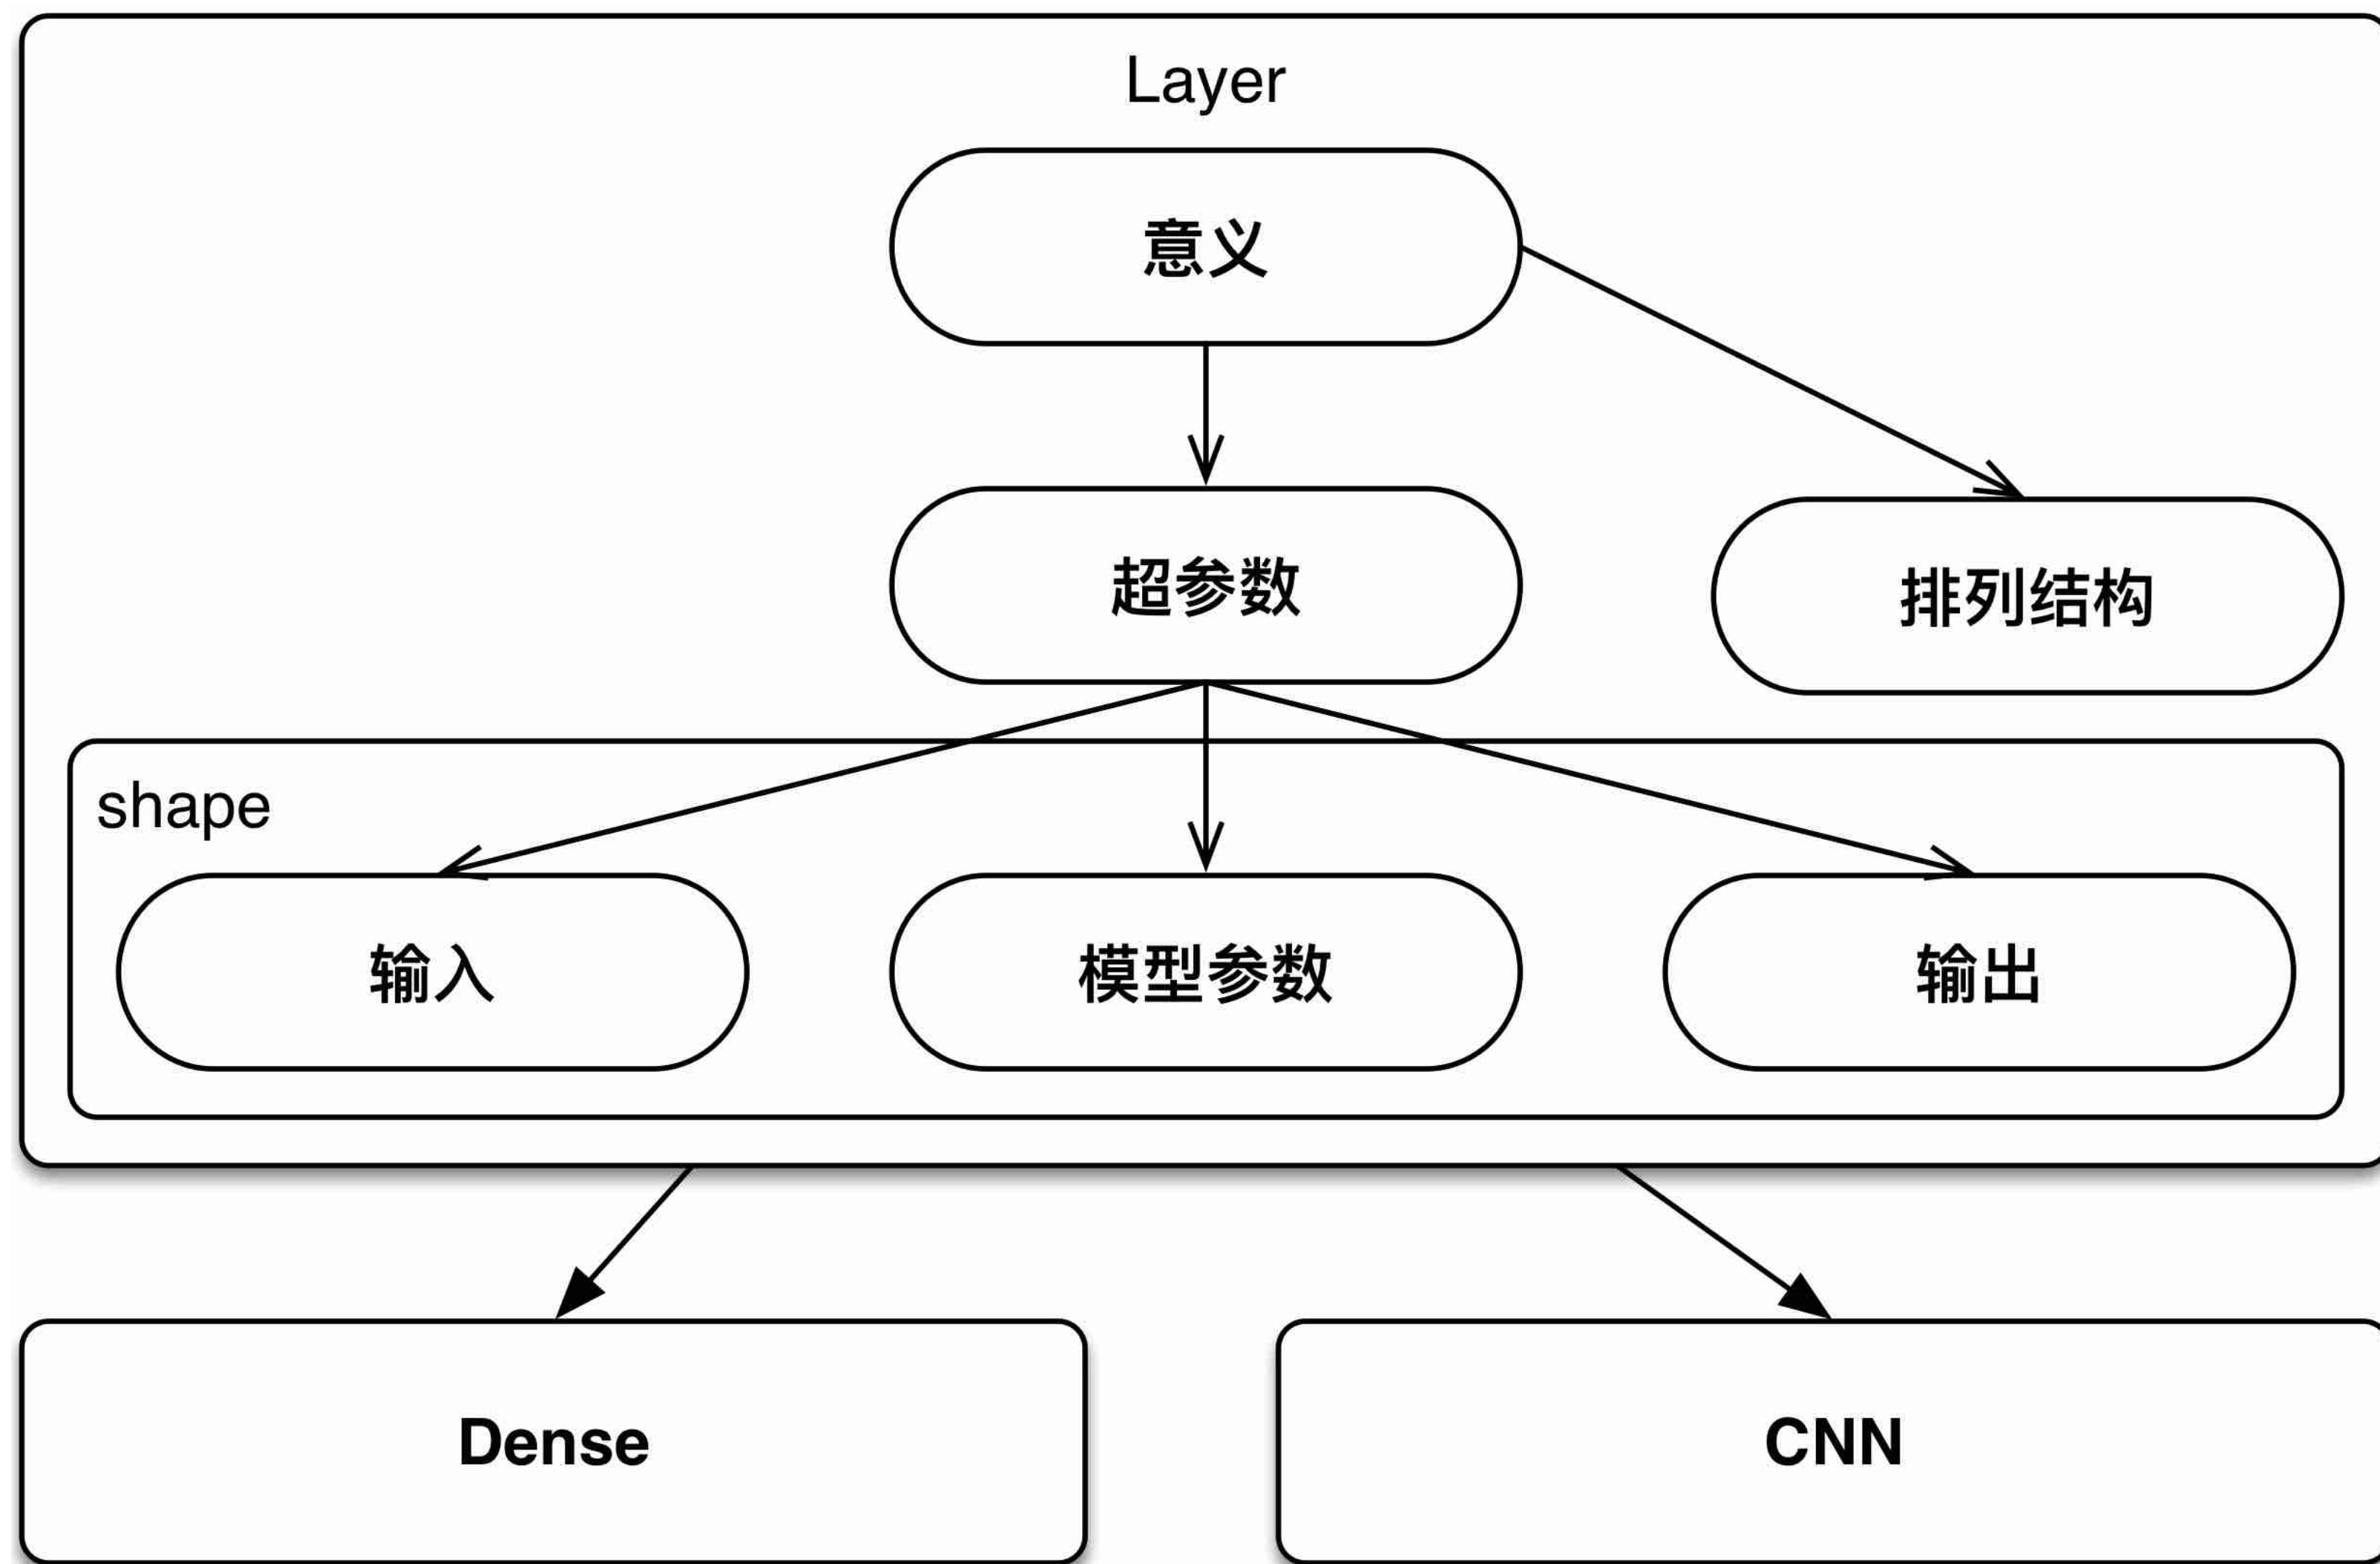


# CNN & RNN


# Dense & CNN

# 学习路线



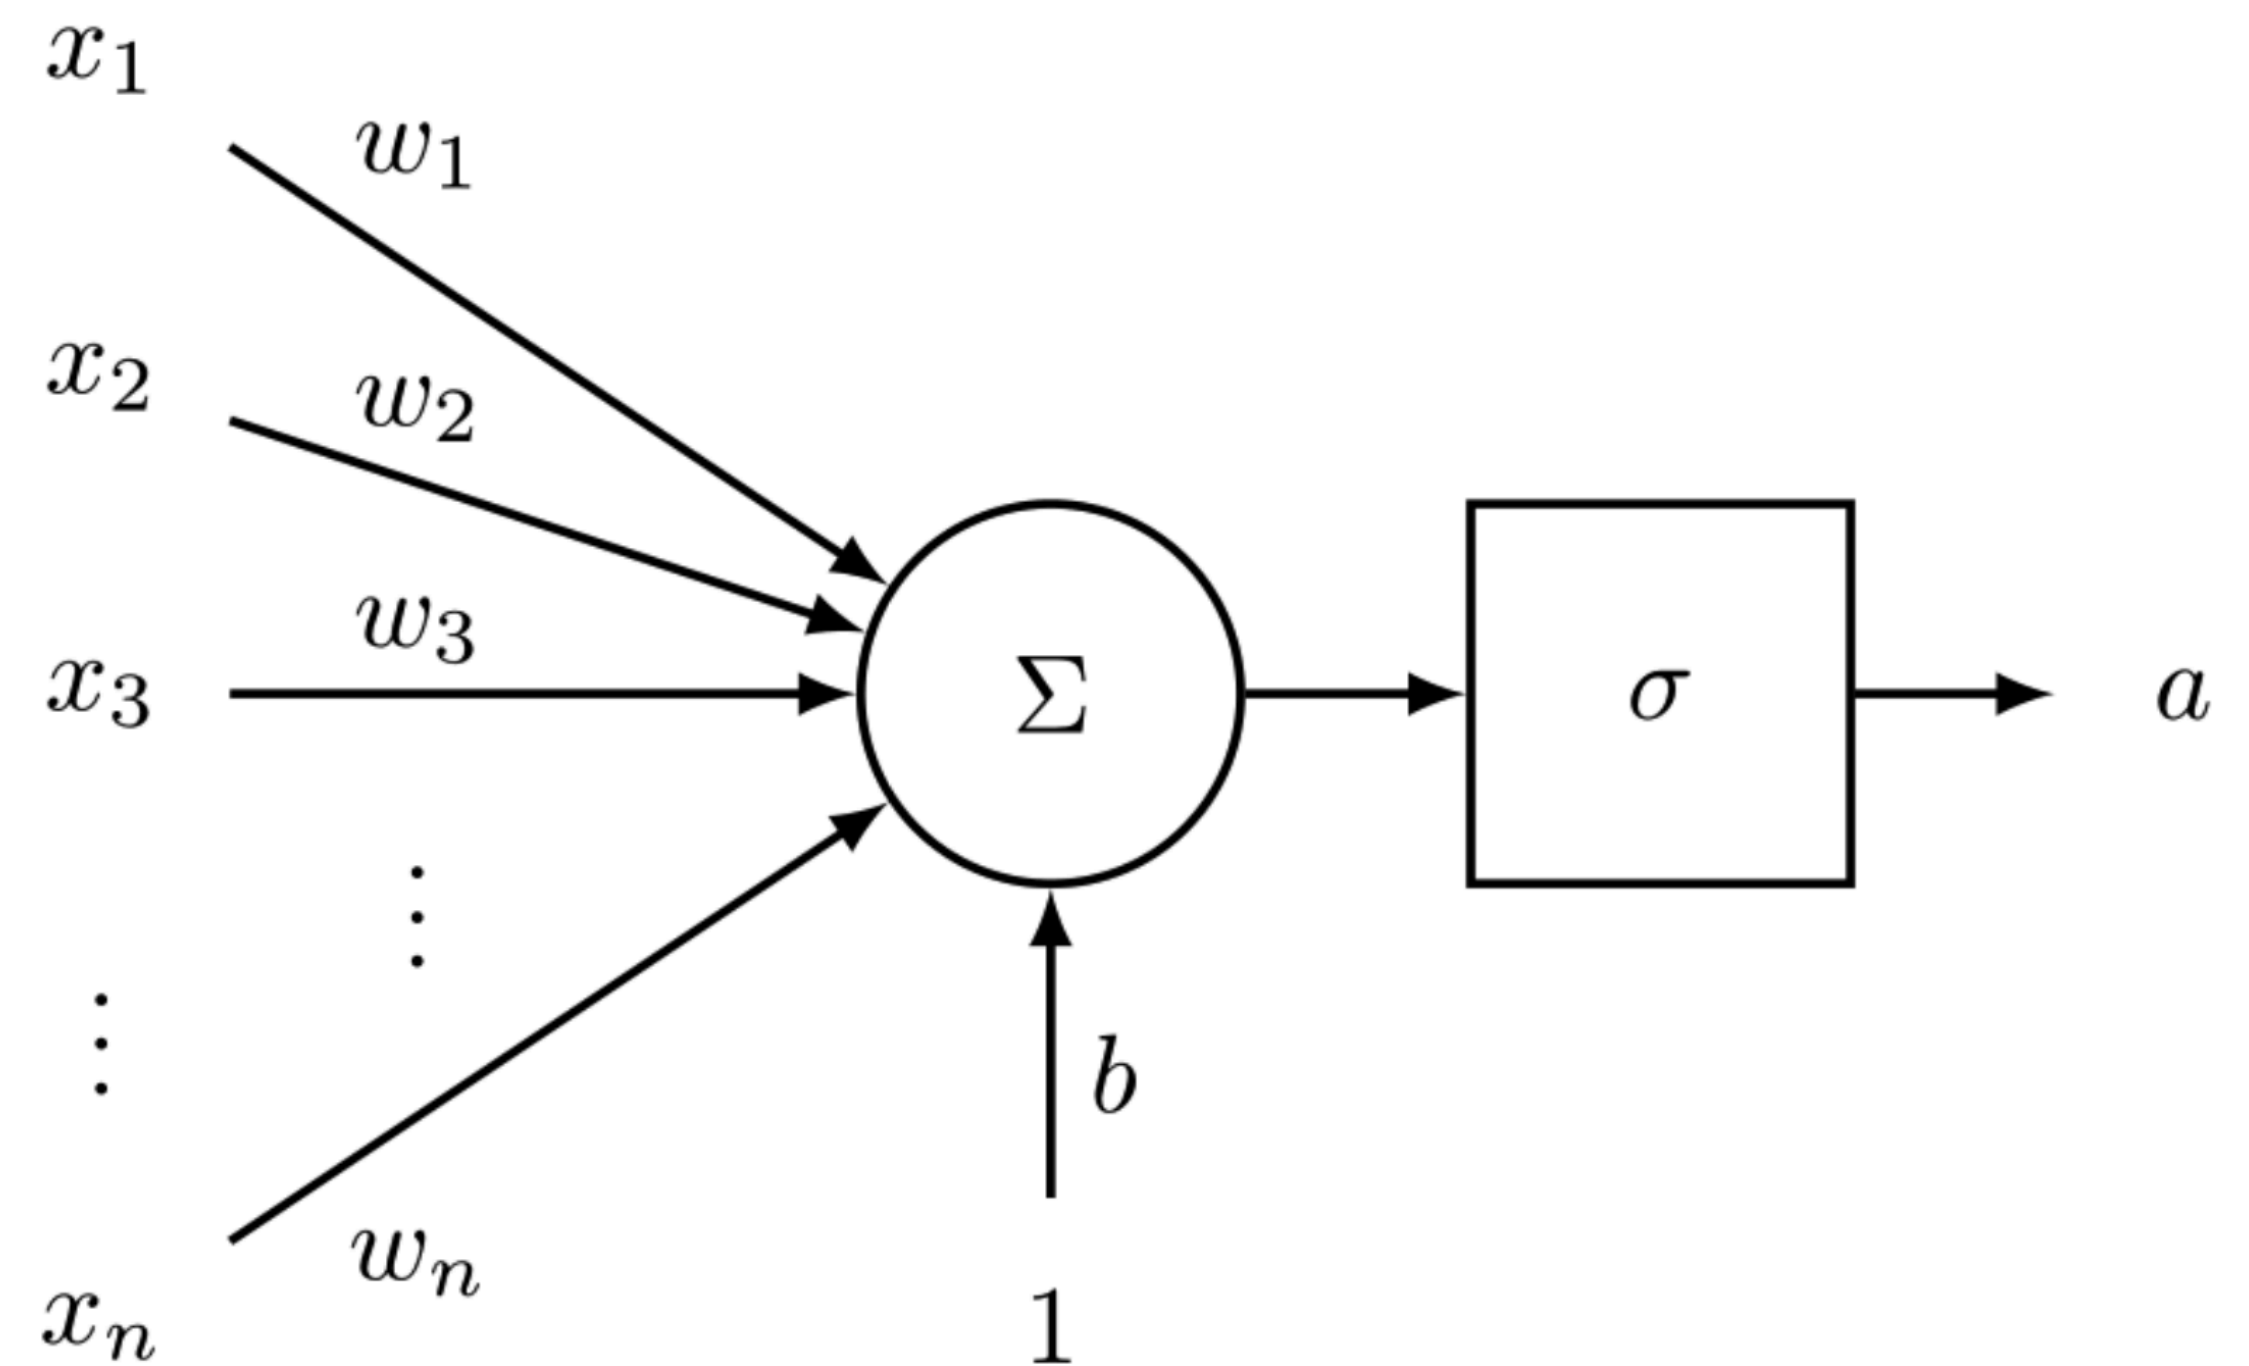
# 形象化Tensor

- 对于一个4\*5\*6的Tensor
  - rank : 3d
  - length: 4, 5, 6
  - shape: [4, 5, 6]
  - volume:  $4*5*6=120$



# 从Neuron到Layer

- 单个神经元:
  - 输入是1d, 参数是1d, 输出是0d
- 一层神经元构成一个Layer
  - 显然输出的shape和Layer的shape一致.
- batch\_size
  - 会影响输出的shape
  - 并不会影响参数的shape



# Dense

- 意义: 多层Dense构成MLP, 用于解分类问题.
- 排列结构: Layer的结构是1d
- 超参数: 神经元的个数U
- shape:
  - input = L
  - weights = L\* U
  - output = U

```
tf.layers.dense(  
    inputs,  
    units,  
    activation=None,  
    use_bias=True,  
    kernel_initializer=None,  
    bias_initializer=tf.zeros_initializer(),  
    kernel_regularizer=None,  
    bias_regularizer=None,  
    activity_regularizer=None,  
    kernel_constraint=None,  
    bias_constraint=None,  
    trainable=True,  
    name=None,  
    reuse=None  
)
```

# CNN组成

- convolutional layers 卷积层
- pooling layers 采样层
- normalization layers 正则层(dropout)
- MLP 分类器


# MLP处理图像

- 考虑用MLP来处理一张图像
  - 图像单个像素点的颜色RGB值表示
  - 一张200x200x3的图片
  - 单个神经元有 $200*200*3 = 120,000$ 参数!




# CNN

- 卷积网络 (Convolutional neural network, 简称CNN)
- 特点：局部区域的权重 $W$ 共用  
(**weight sharing**) (空间维度)
- 每一个卷积层后通常紧跟着一个下采样层subsample, 比如采用max-pooling 方法完成下采样。




# 2d卷积核

- 卷积核是一个多维数组，参数由学习算法得到的
- 定义输入的长度(W), 卷积核的大小(F), 核移动的步长stride(S), zero padding(P)
- 输出的长度 $L = (W-F+2P)/S+1$
- 并行化: 做一个和输出一样大小的Layer, Layer里面所有的神经元参数都一样!



# 3d卷积核



- 输入是3d的
- 有多个卷积核

# 卷积层


- 意义: 用于处理图像.
- 排列结构: Layer的结构是3d
- 超参数: 卷积核个数(D), 核大小(F), padding(P), strides(S)
- shape:
  - Input =  $W \times W \times 3$
  - $L = (W - F + 2P) / S + 1$
  - Layer =  $L \times L \times D$
  - Weights =  $F \times F \times D$
  - Output =  $L \times L \times D$

```
tf.layers.conv2d(  
    inputs,  
    filters,  
    kernel_size,  
    strides=(1, 1),  
    padding='valid',  
    data_format='channels_last',  
    dilation_rate=(1, 1),  
    activation=None,  
    use_bias=True,  
    kernel_initializer=None,  
    bias_initializer=tf.zeros_initializer(),  
    kernel_regularizer=None,  
    bias_regularizer=None,  
    activity_regularizer=None,  
    kernel_constraint=None,  
    bias_constraint=None,  
    trainable=True,  
    name=None,  
    reuse=None  
)
```




# Pooling层

- 意义: 采样, 缩小模型大小
- 排列结构: Layer的结构是3d
- 超参数: pooling\_type, window\_shape, padding, strides
- 一个2\*2核, strides=2的pooling层, 等于减少75%的输出
- pooling层并不会改变tensor的深度




# Dropout层


- 意义: 减少CNN过拟合问题
- 超参数: keep\_prob 丢弃率
- 对于所有的输入, 有keep\_prob概率保留并乘以 $1/\text{keep\_prob}$ , 以保证前后总和大致相等, 否则输出0




(a) Standard network



(b) Dropout network



(a) Standard Neural Net



(b) After applying dropout.

# 共享Variable

```
def my_image_filter(input_images):  
    with tf.variable_scope("conv1"):  
        # Variables created here will be named "conv1/weights", "conv1/biases".  
        relu1 = conv_relu(input_images, [5, 5, 32, 32], [32])  
    with tf.variable_scope("conv2"):  
        # Variables created here will be named "conv2/weights", "conv2/biases".  
        return conv_relu(relu1, [5, 5, 32, 32], [32])
```



```
with tf.variable_scope("model") as scope:  
    output1 = my_image_filter(input1)  
scope.reuse_variables()  
    output2 = my_image_filter(input2)
```


生成两套参数

```
with tf.variable_scope("model") as scope:  
    output1 = my_image_filter(input1)  
    scope.reuse_variables()  
    output2 = my_image_filter(input2)
```

共享一套参数



# 课后作业

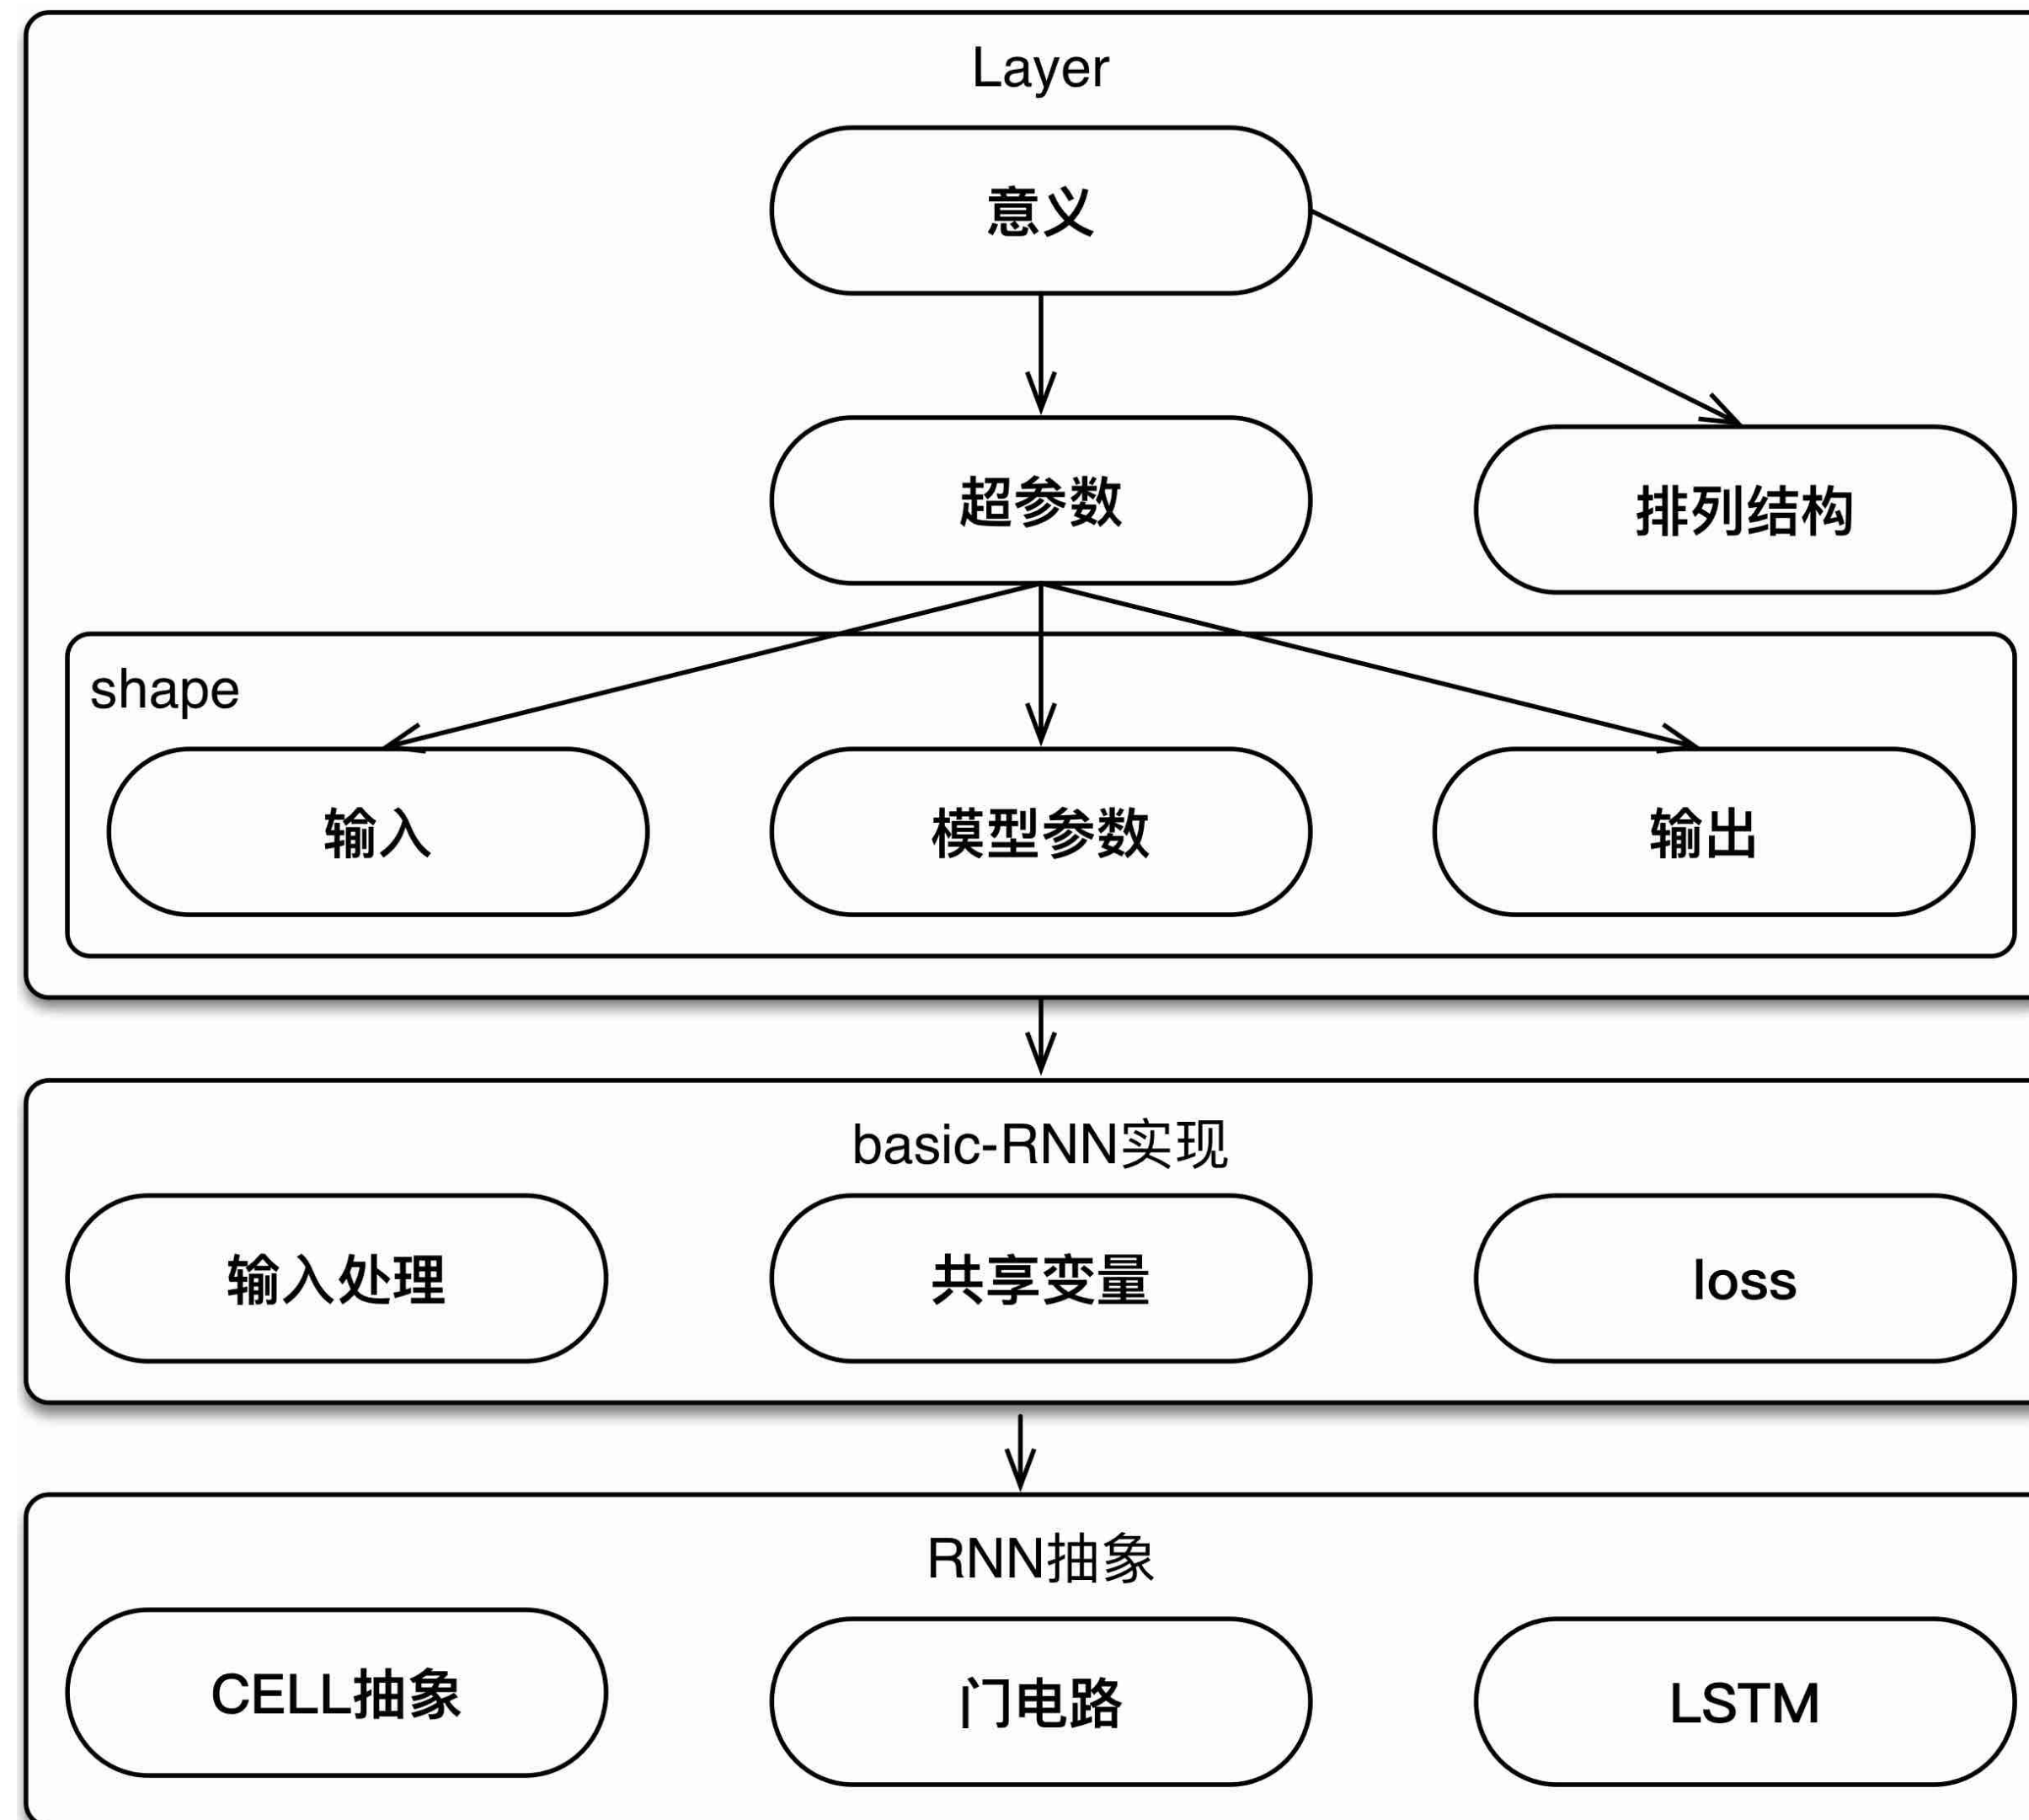


阅读 Alex Krizhevsky, Ilya Sutskever and Geoffrey E. Hinton. "ImageNet classification with deep convolutional neural networks." NIPS 2012.



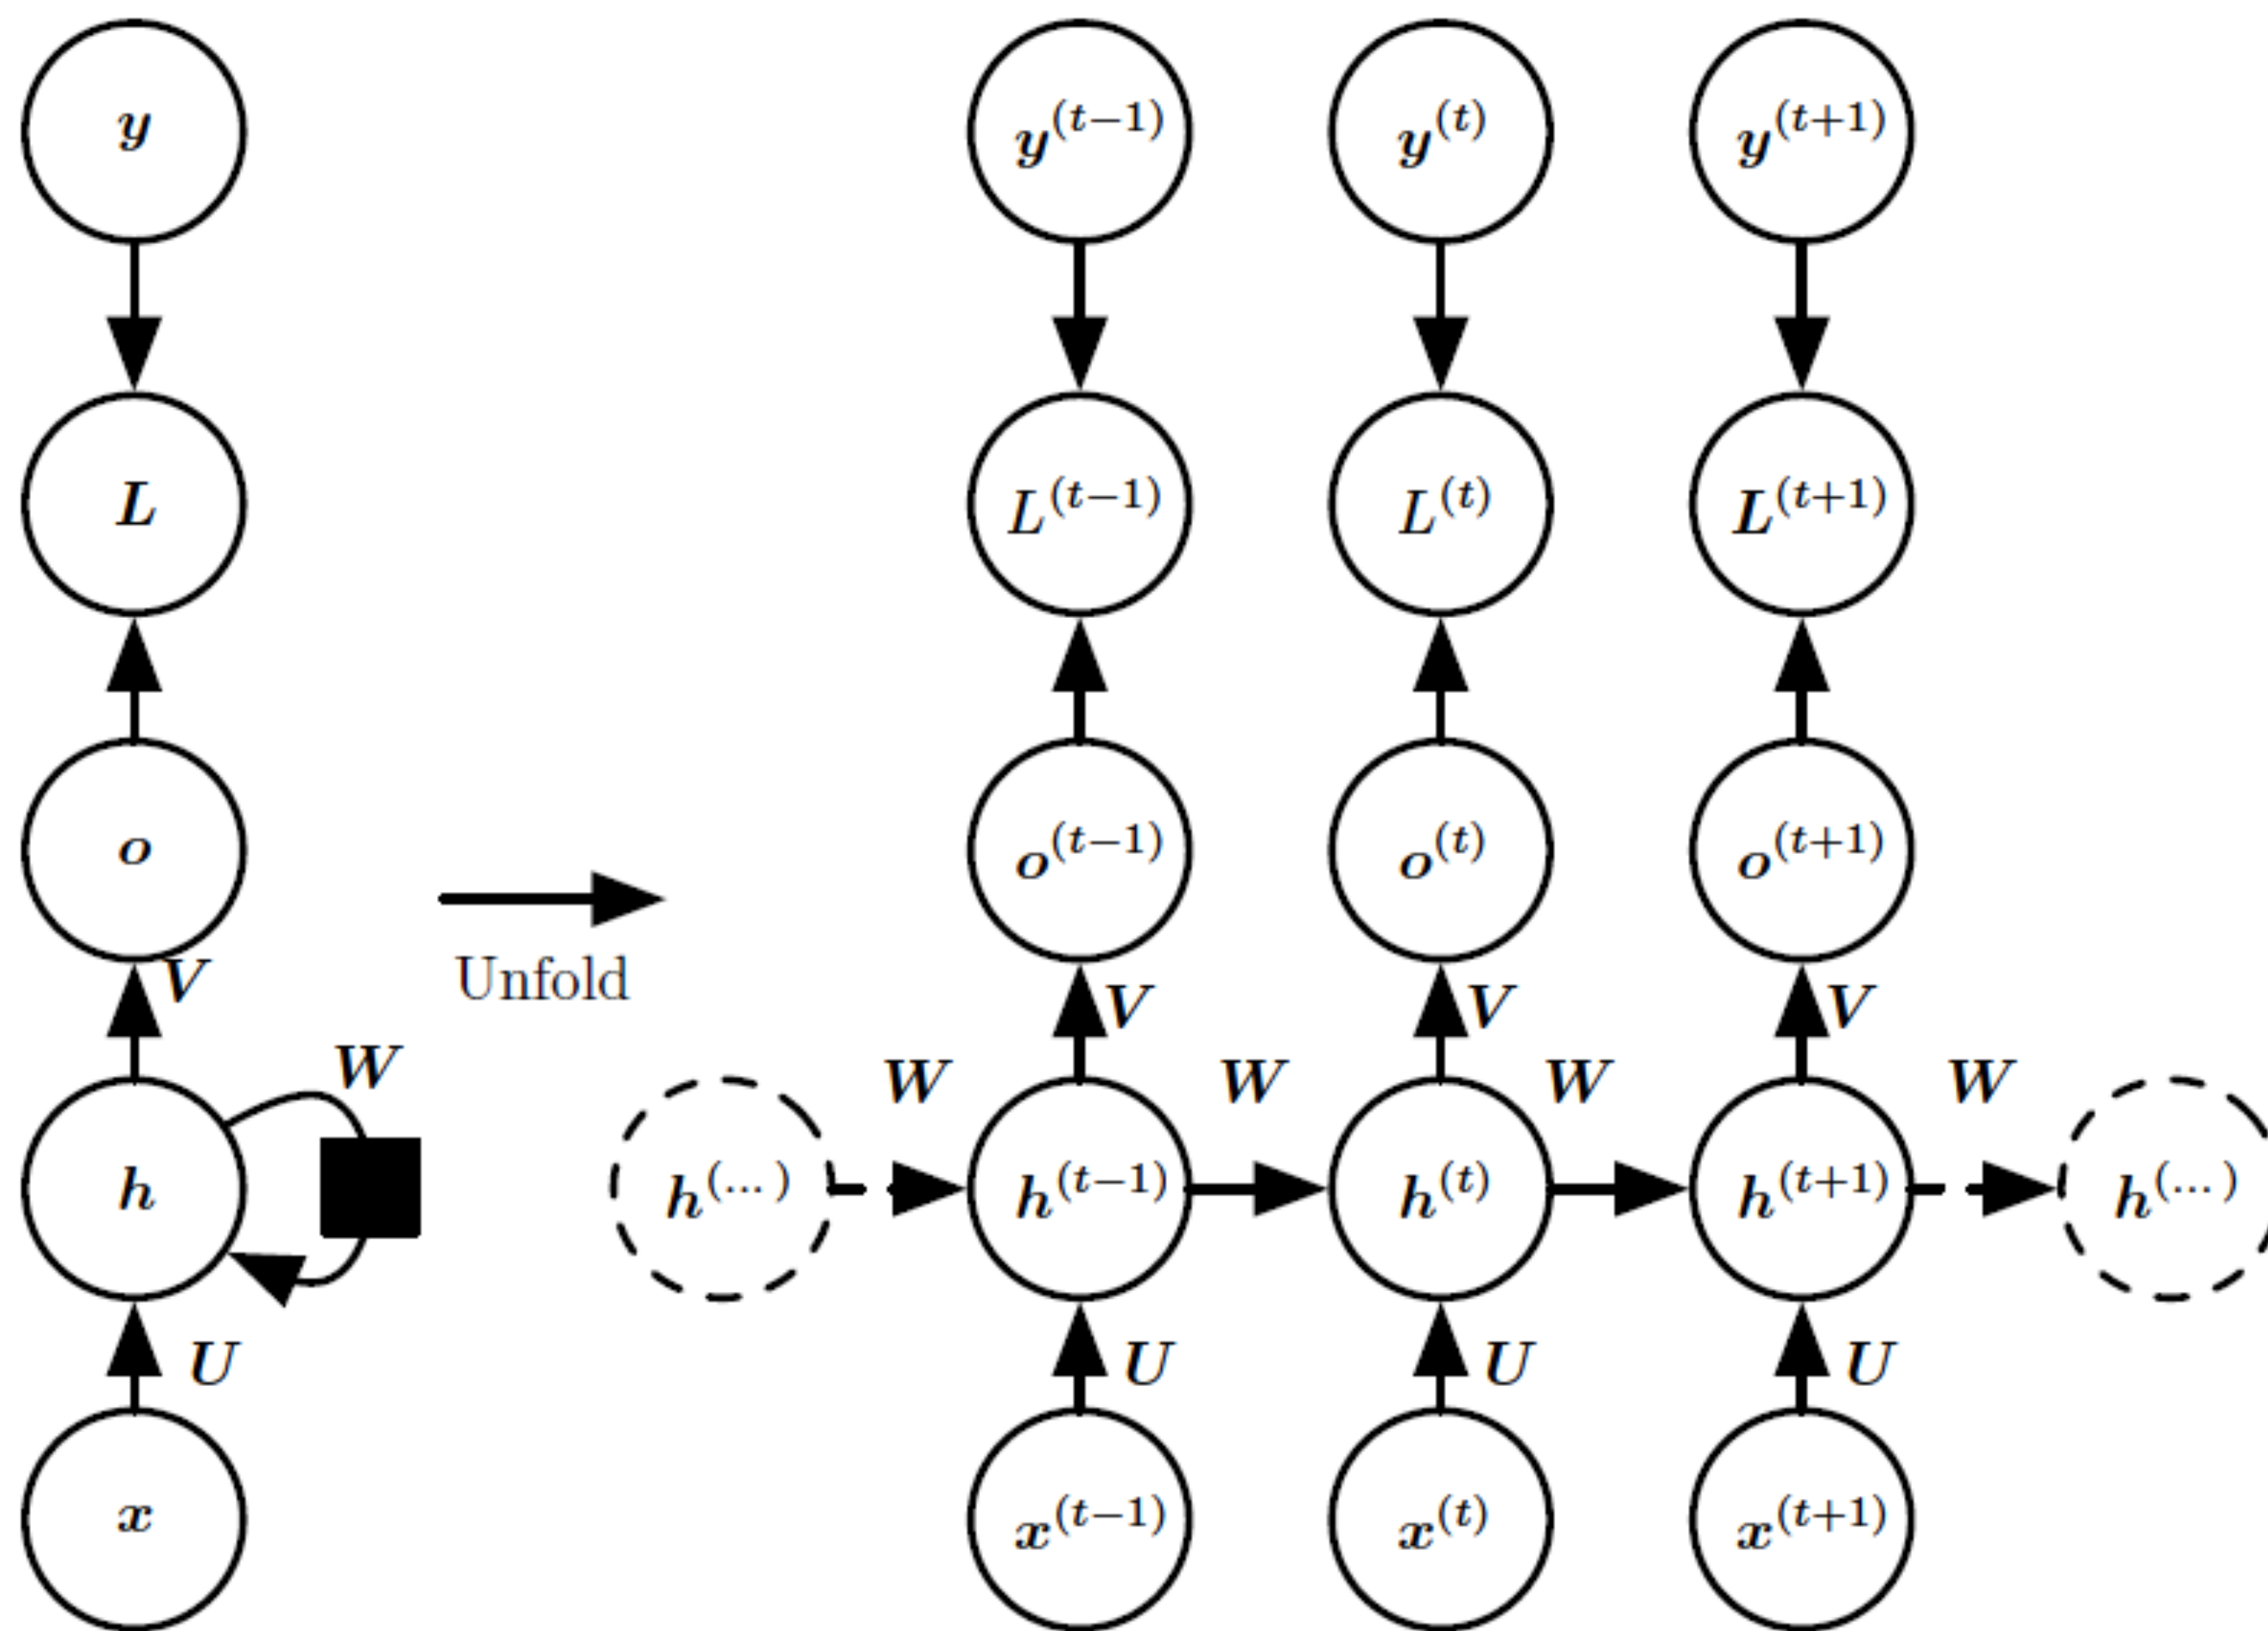
# RNN & LSTM

# 学习路线



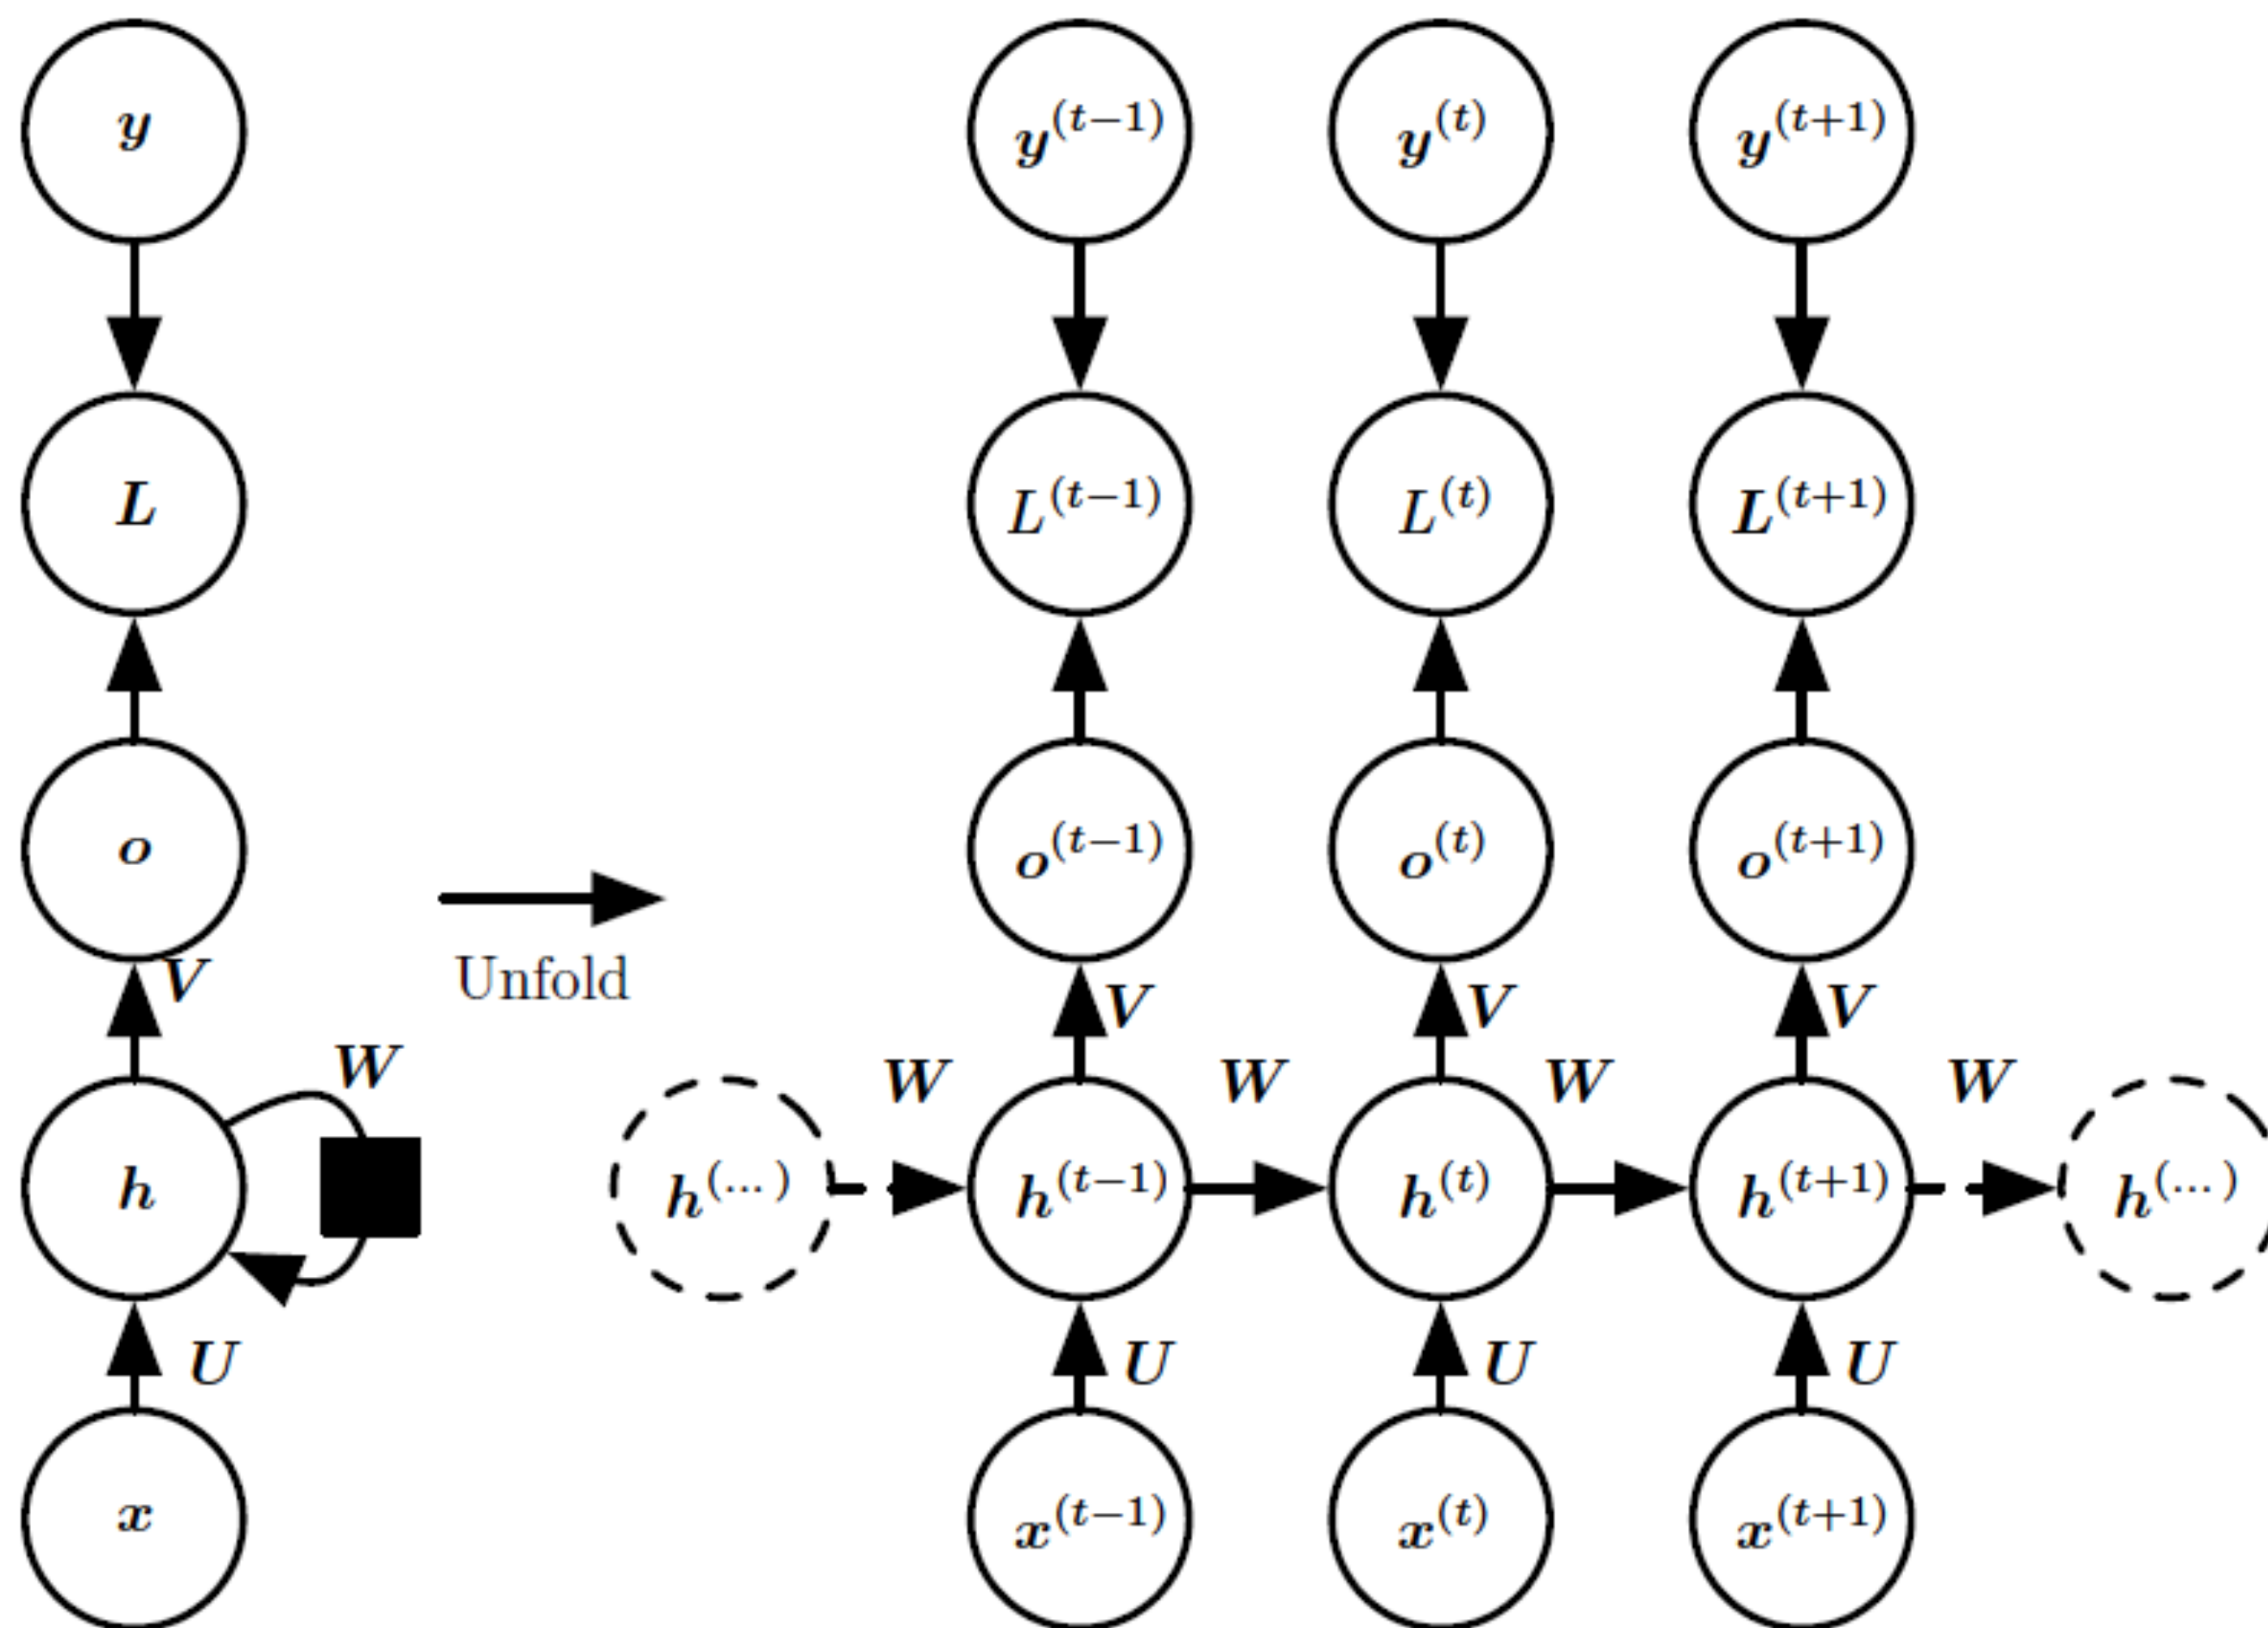
# RNN

- 循环网络结构
  - $y$ 是训练目标
  - $L$ 是损失函数
  - $o$ 是网络输出
  - $h$ 是状态（隐藏单元）
  - $x$ 是网络输入
- 计算图的时间步上展开
- 举例：天气预测



# 权重共享

- 循环神经网络在不同的时间步上采用相同的  $U$ 、 $V$ 、 $W$  参数
- 输入到隐藏的连接由权重矩阵  $U$  参数化
- 隐藏到输出的连接由权重矩阵  $V$  参数化
- 隐藏到隐藏的循环连接由权重矩阵  $W$  参数化



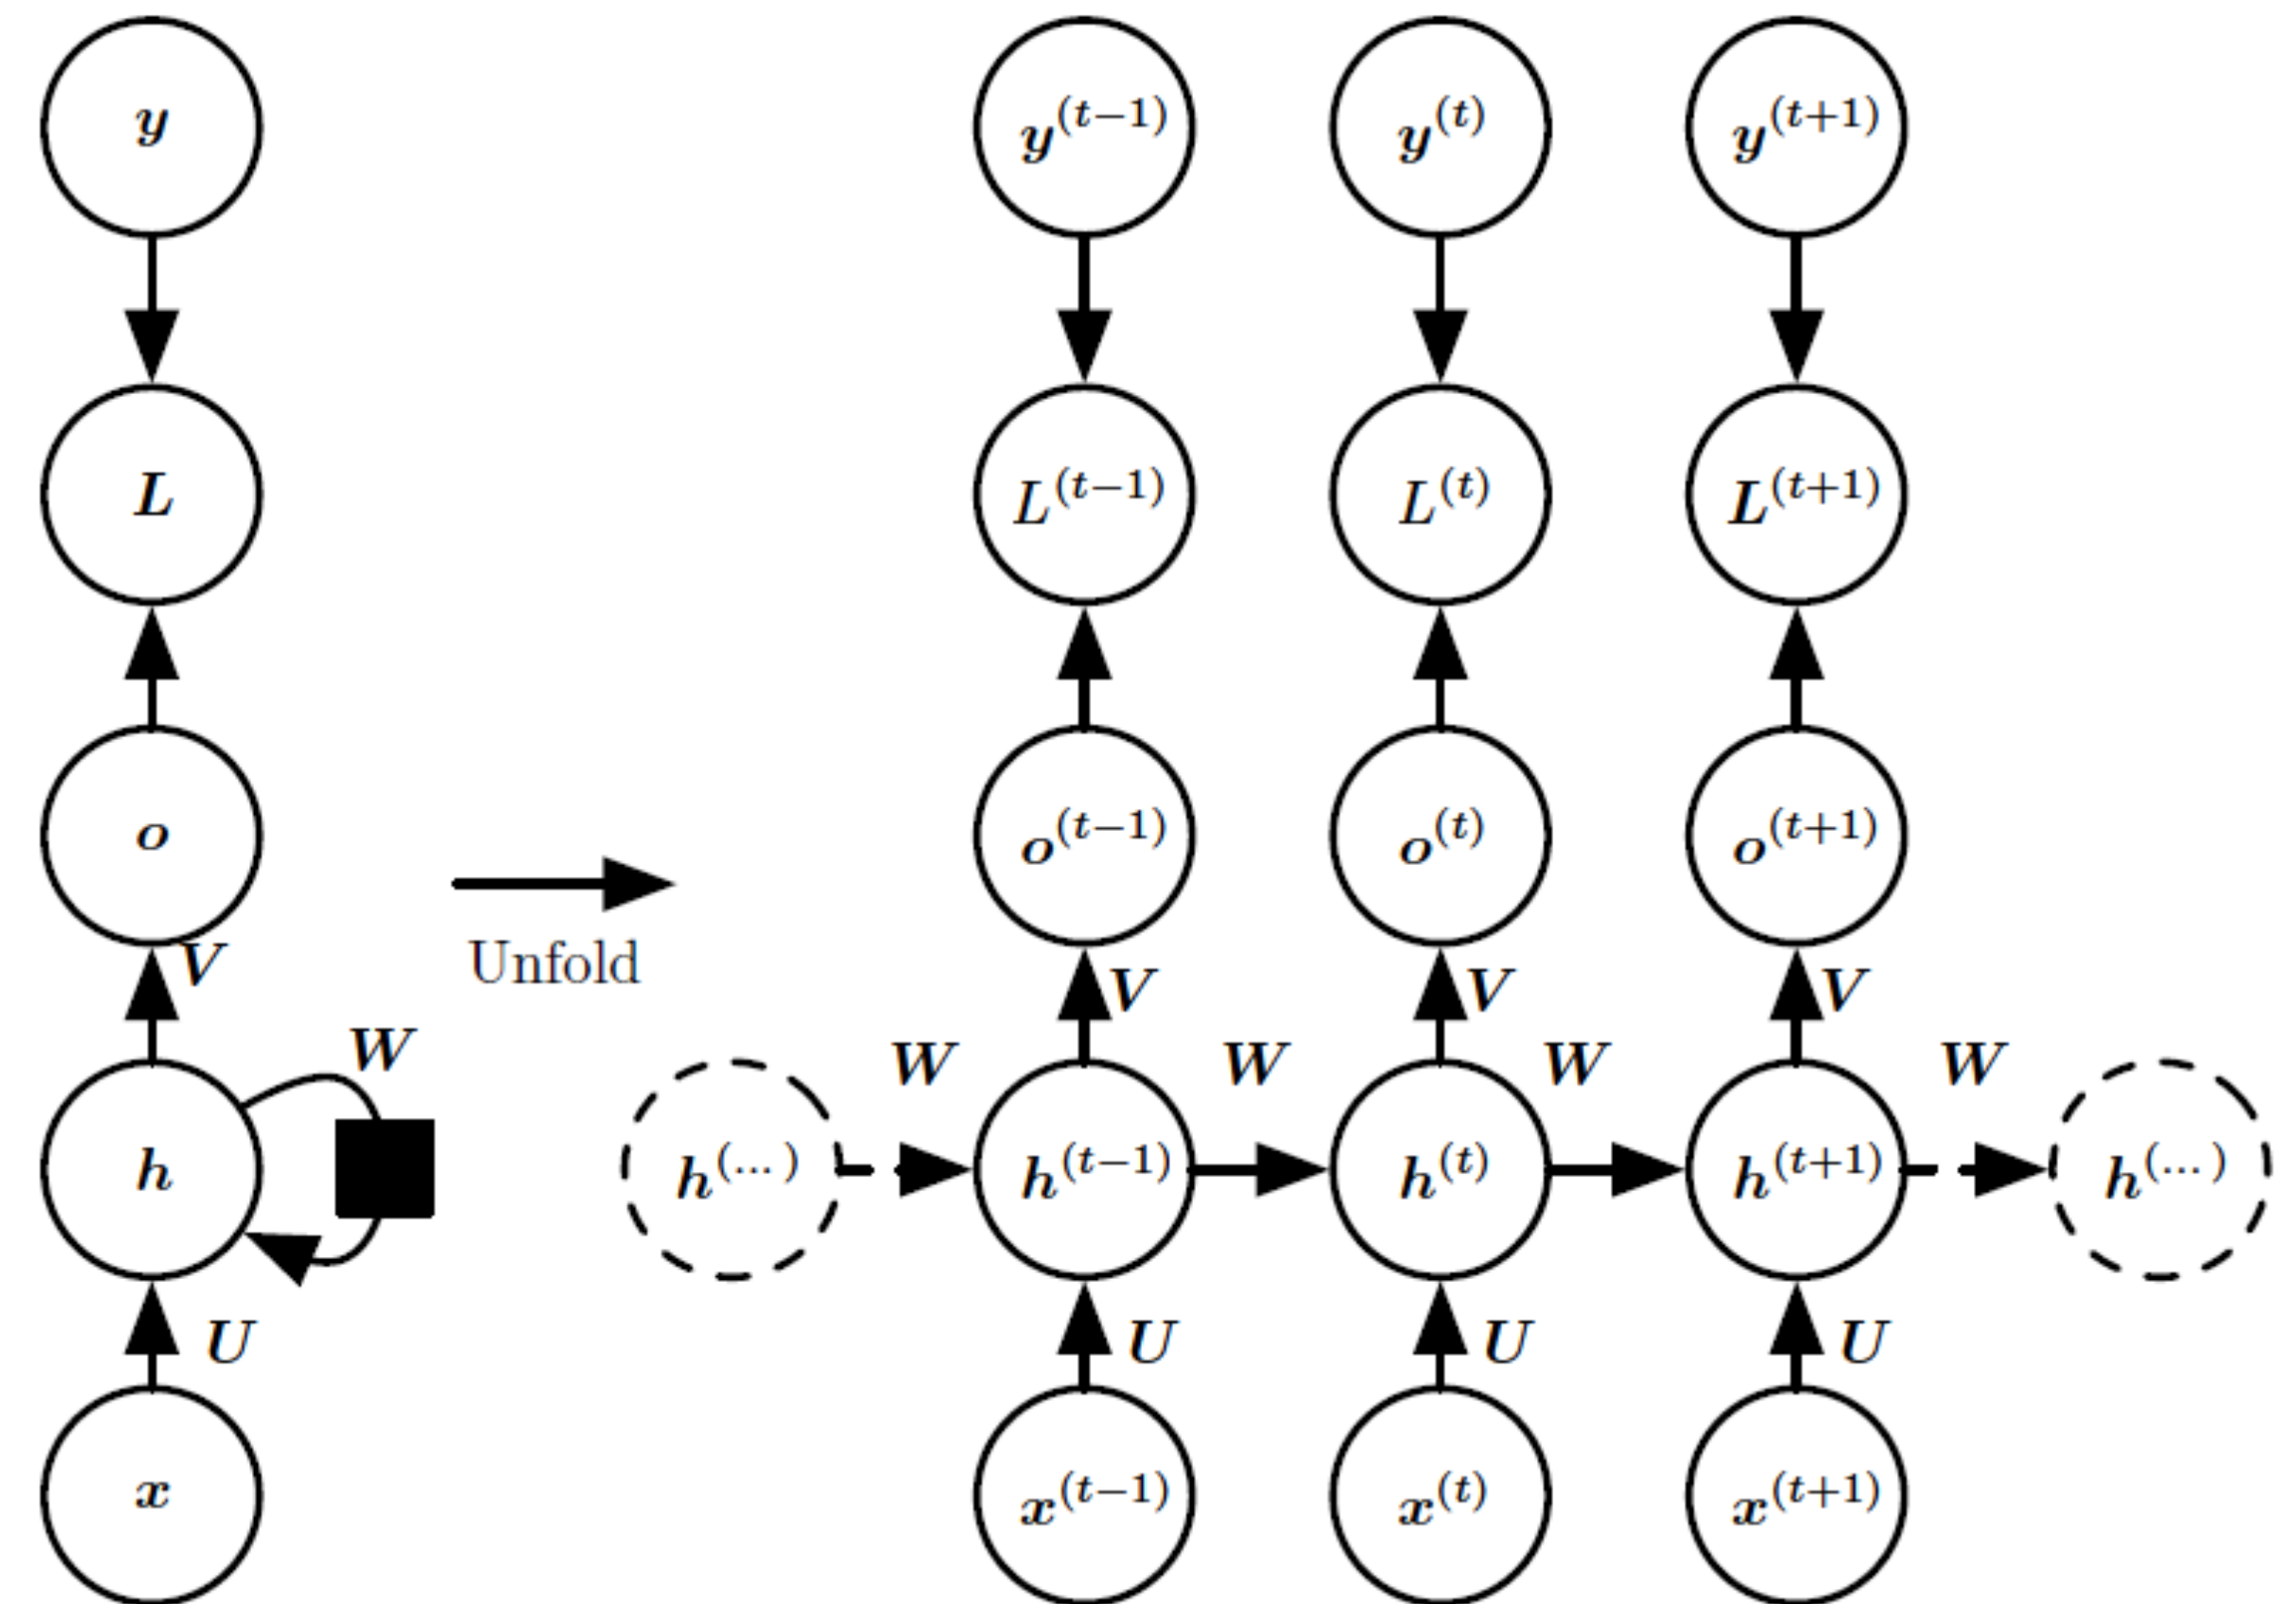
# 计算图

$$a^{(t)} = b + Wh^{(t-1)} + Ux^{(t)},$$

$$h^{(t)} = \tanh(a^{(t)}),$$

$$o^{(t)} = c + Vh^{(t)},$$

$$\hat{y}^{(t)} = \text{softmax}(o^{(t)}),$$



- 循环网络将一个输入序列映射到相同长度的输出序列。
- 信息流动路径：信息在时间上向前（计算输出和损失）和向后（计算梯度）的思想。
- $U$ 、 $V$  和  $W$  分别对应于输入到隐藏、隐藏到输出和隐藏到隐藏的连接权重矩阵。
- $b$  和  $c$  是偏置向量。

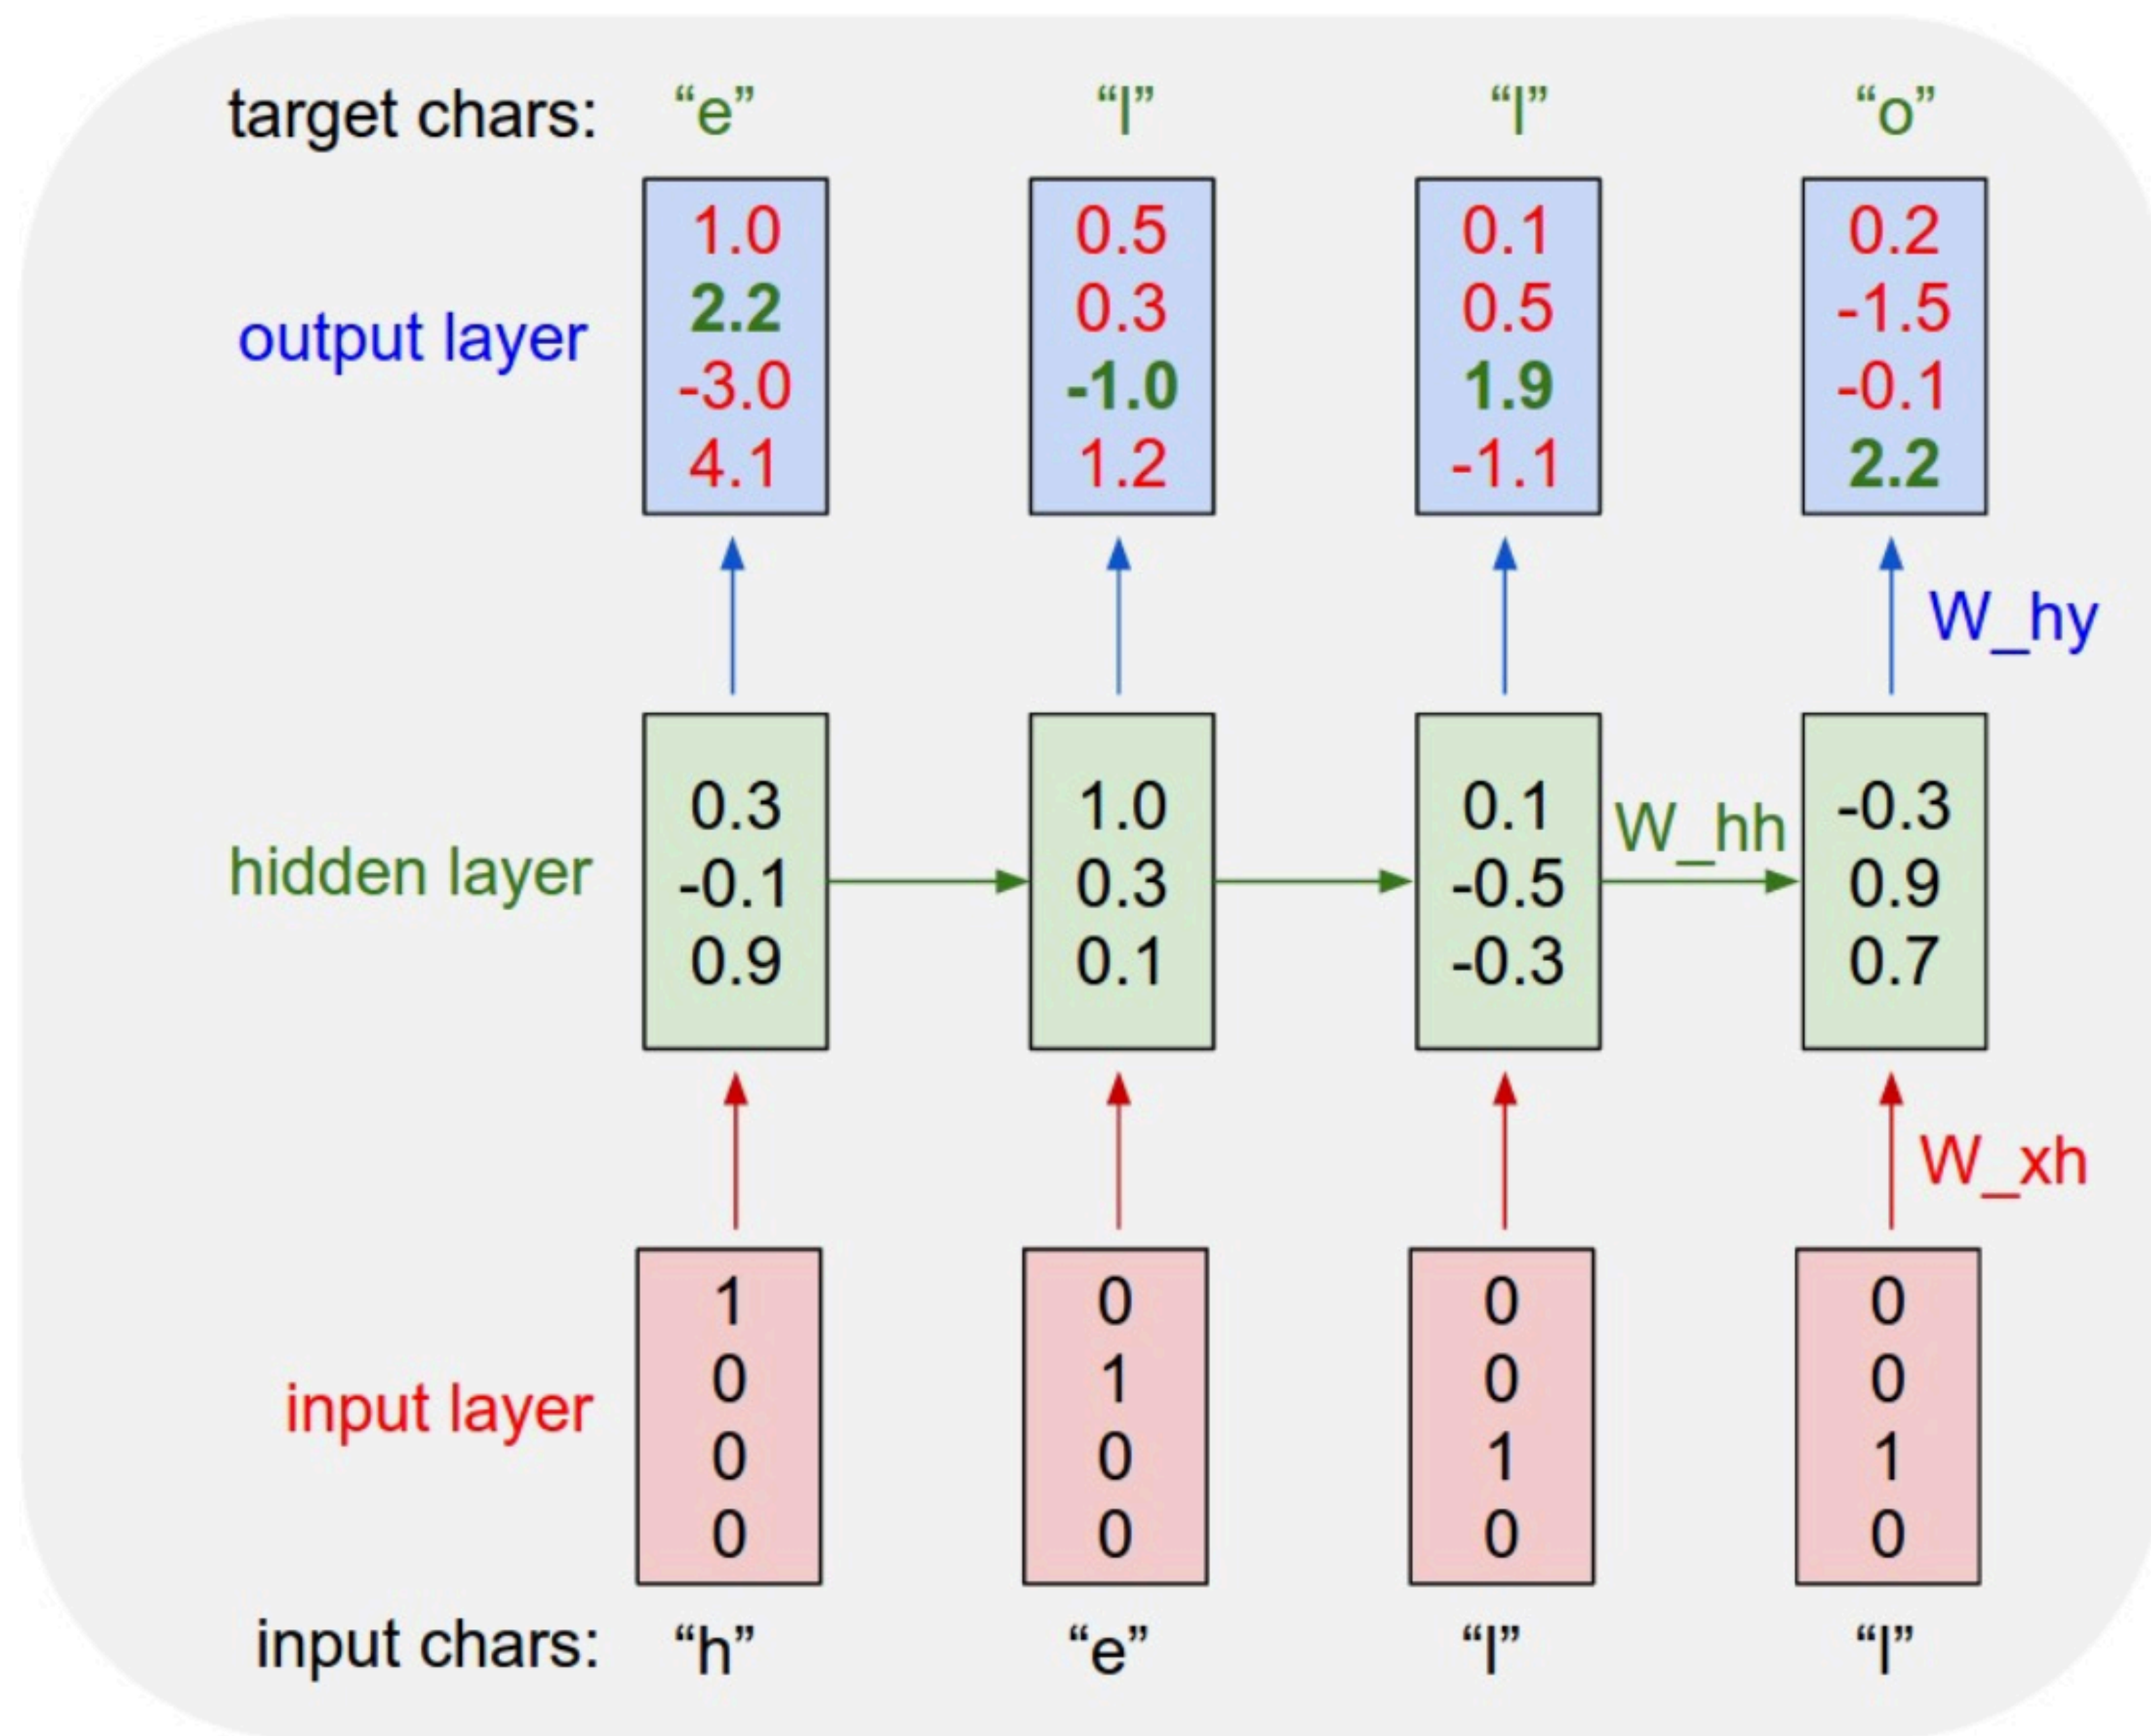


# basic-rnn 实现

```
iter: 646500, p: 1300, loss: 0.019042
----
y = tf.get_variable("by", [vocab_size], initializer=initializer)
    by = tf.get_variable("by", [vocab_size], dtype=tf.float32, name="state:
hprev_val = np.zeros([1, hidden_size])

while True:
```

- [3 NeuralNetworks/min-char-rnn-tensorflow.py](#)
- Andrej Karpathy的min-char-rnn tf版本实现
- 实现了一个自动写代码的程序, 输入程序就是本身



# 输入和loss处理

- 给定序列长度(模型超参数), 把输入序列化
- one-hot 离散化处理
- **U, V, W 共享权重**
- 收集所有时刻的输出, 计算的loss
- 梯度截取预防梯度爆炸

$$\begin{aligned} L(\{\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(\tau)}\}, \{\mathbf{y}^{(1)}, \dots, \mathbf{y}^{(\tau)}\}) \\ &= \sum_t L^{(t)} \\ &= - \sum_t \log p_{\text{model}}(y^{(t)} \mid \{\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(t)}\}) \end{aligned}$$



# rnn-cell抽象

```
__init__(
    num_units,
    activation=None,
    reuse=None,
    name=None
)
```

**Cell超参数: num\_units**

```
__call__(
    inputs,
    state,
    scope=None,
    *args,
    **kwargs
)
```

**调用时刻要输入state**

```
tf.nn.static_rnn(
    cell,
    inputs,
    initial_state=None,
    dtype=None,
    sequence_length=None,
    scope=None
)
```

**static-rnn抽象**

```
state = cell.zero_state(...)
outputs = []
for input_ in inputs:
    output, state = cell(input_, state)
    outputs.append(output)
return (outputs, state)
```

**rnn-example**

# rnn-cell抽象

- hidden-units : 模型的容量大小
- $I(\text{input}) + S(\text{state}) \rightarrow O(\text{output}) + S(\text{new\_state})$
- inputs: 输入
- state: 隐含了之前所有的输出信息
- 当前的输出完全取决于state和当前的输入


# dynamic-rnn

- 3 NeuralNetworks/dynamic\_rnn.py
- 动态生成计算图
- 不需要固定序列长度

```
tf.nn.dynamic_rnn(  
    cell,  
    inputs,  
    sequence_length=None,  
    initial_state=None,  
    dtype=None,  
    parallel_iterations=None,  
    swap_memory=False,  
    time_major=False,  
    scope=None  
)
```


# LSTM

- RNN训练有以下问题
  - RNN梯度爆炸
  - RNN梯度消失
- LSTM解决以上问题




# LSTM

- LSTM是RNN的一个改进，LSTM增加了一个主输入单元和其他三个辅助的门限输入单元：输入门（Input gate）控制是否输入，遗忘门（Forget gate）控制是否存储，输出门（Output gate）控制是否输出。
- 辅助单元可以寄存时间序列的输入，在训练过程中会利用后向传播的方式进行。
- 记忆单元和这些门单元的组合，大大提升了RNN处理远距离依赖问题的能力，解决RNN网络收敛慢的问题。



# 门电路

- Input和Control形状一致
- Control经过Sigmoid函数后, 变成一个范围在0-1之间的一个同形状的Tensor
- Input和 $\sigma(\text{Control})$  元素相乘等到一个同形的Output





- RNN

$$h_t = \mathcal{H}(W_{xh}x_t + W_{hh}h_{t-1} + b_h) \quad (1)$$

$$y_t = W_{hy}h_t + b_y \quad (2)$$

- LSTM


$$i_t = \sigma(W_{xi}x_t + W_{hi}h_{t-1} + W_{ci}c_{t-1} + b_i) \quad (3)$$

$$f_t = \sigma(W_{xf}x_t + W_{hf}h_{t-1} + W_{cf}c_{t-1} + b_f) \quad (4)$$

$$c_t = f_t c_{t-1} + i_t \tanh(W_{xc}x_t + W_{hc}h_{t-1} + b_c) \quad (5)$$

$$o_t = \sigma(W_{xo}x_t + W_{ho}h_{t-1} + W_{co}c_t + b_o) \quad (6)$$

$$h_t = o_t \tanh(c_t) \quad (7)$$



# 推荐阅读

- [The Unreasonable Effectiveness of Recurrent Neural Networks](#)
- [Understanding-LSTMs](#)



**谢谢!**